

# Mesurer la diversité qu'un fil algorithmique expose réellement

Une norme, ses attaques, et ce qu'il faut pour la vérifier

Sylvain Geffroy

Août 2026 — *document de travail ouvert à la relecture*

## Résumé

Un régulateur qui veut contraindre un algorithme de recommandation a besoin d'une grandeur qu'il puisse constater sans accéder au code de la plateforme. Cette note propose une telle grandeur — l'**Indice de Diversité Exposée** (IDE), l'entropie des contenus servis projetés sur un catalogue de points de vue déclaré, pondérée par l'attention qu'appelle chaque rang — puis la soumet aux attaques qu'elle doit supporter pour valoir comme norme.

Trois de ces attaques réussissent contre les formulations naïves, et chacune impose une correction. Un plancher portant sur les *étiquettes* d'un fil est saturé à coût nul : une plateforme capable de dissocier l'étiquette du contenu obtient la note maximale pour une diversité de contenu strictement nulle. L'entropie quadratique de Rao, premier remplaçant envisagé, a un optimum sous contrainte *bimodal* : elle prescrirait la polarisation qu'elle prétend mesurer. Et toute mesure aveugle au rang se laisse satisfaire en *enterrant* les contenus divergents — une plateforme certifiée à 0,70 n'expose que 0,36 de diversité réelle, et fermer l'échappatoire double le coût d'engagement.

Vérifier une telle norme sur données réelles exige de connaître l'*exposition* : nous donnons trois contrôles à passer sur un journal de recommandation — l'ordre y dit-il quelque chose, y a-t-il de quoi estimer, et sous quelle forme — et les appliquons à trois journaux publics. MIND ne conserve pas l'ordre servi, et l'estimateur usuel y produit cinq sévérités incompatibles ; Baidu-ULTR le conserve ; l'Open Bandit Dataset permet la seule confrontation de ce travail à une vérité terrain, où la valeur d'une politique jamais déployée est retrouvée à 2,5 % contre 31,6 % d'erreur pour l'estimation naïve.

La conclusion principale de cette partie est cependant négative pour la méthode que nous venions de construire. Baidu-ULTR publie une colonne de temps d'affichage qui permet de **mesurer** l'exposition au lieu de l'estimer à travers les clics : la sévérité y vaut alors  $0,88 \pm 0,05$  sur 143 documents, et non  $1,09 \pm 0,09$  sur 55 — l'estimation surestime la décroissance de 23 %, parce qu'un clic mélange l'examen et l'attrait. La mesure directe réfute en outre le modèle à cascade sur ce journal, par deux voies indépendantes, et montre que la loi  $R^{-\eta}$  est le pire des trois ajustements sur la courbe observée. Enfin, un format d'affichage enrichi placé au-dessus retire 8,4 points d'examen à ce qui suit, à rang et à hauteur de page comparables : la pondération de rang n'est donc pas une propriété du rang, ni même de la surface, mais de la **page servie**.

Aucun jeu public ne porte à la fois le rang servi et une étiquette de point de vue interprétable. Nous spécifions donc, au titre de l'article 40 du *Digital Services Act*, des tableaux agrégés sans donnée personnelle, dont il est vérifié qu'ils recalculent les mesures à l'identique pour cent fois moins de lignes qu'un journal brut.

La partie II expose le modèle thermodynamique d'où l'indice est issu, et §15 rend compte de ce qu'il en reste : l'analogie avec la décohérence quantique qui a lancé ce travail ne survit à aucun de ses transferts. L'ensemble du code, des tests et des figures est reproductible en conteneur.

## Première partie

# La mesure

## 1 Le problème métrologique

Réguler un algorithme de recommandation suppose une grandeur constatable. Compter les contenus problématiques ne convient pas : l'indicateur est retardé, manipulable, et il demande de trancher sur le fond de chaque contenu. La grandeur retenue ici est d'une autre nature — elle porte sur la *forme* de l'exposition, non sur le contenu des messages :

Quelle part de l'attention servie à un lecteur va à chacun des points de vue que la plateforme aurait pu lui servir ?

Cette question a trois qualités : elle se mesure depuis l'extérieur, elle ne demande aucun jugement sur la véracité d'un contenu, et elle admet un seuil exprimé en pourcentage, donc transposable d'une plateforme à l'autre.

Elle a aussi trois pièges, et cette note est organisée autour d'eux.

1. **Une étiquette n'est pas un contenu.** Mesurer la diversité des *catégories annoncées* laisse à la plateforme le choix de ce qui est annoncé.
2. **Une composition n'est pas une exposition.** Un fil peut contenir la diversité exigée et la placer là où personne ne regarde.
3. **Un clic enregistré n'est pas une préférence.** Les clics observés ont été produits par le classement de la plateforme, et non par celui qu'on évalue.

Chacun de ces pièges est mesurable, et chacun a été mesuré. Ce qui subsiste après les trois est la définition retenue.

## 2 L'indice de diversité exposée

Soit un fil de  $n$  positions, un catalogue de référence de  $k$  points de vue déclaré par le régulateur, et une remise d'attention  $w_R$  associée au rang  $R$ . La distribution *exposée* est

$$q_i = \frac{\sum_{R=1}^n w_R \mathbb{I}[\text{le contenu servi au rang } R \text{ tombe dans le bac } i]}{\sum_{R=1}^n w_R}, \quad (1)$$

et l'indice est son entropie de Shannon normalisée :

$$\text{IDE} = \frac{H(q)}{\log_2 k}, \quad H(q) = - \sum_{i=1}^k q_i \log_2 q_i. \quad (2)$$

Trois choix distinguent (1) de l'entropie qu'on écrirait spontanément, et chacun est la conséquence d'une attaque qui a réussi (§3).

| Choix                                                                 | Raison                                                                  | Sans lui                                                                               |
|-----------------------------------------------------------------------|-------------------------------------------------------------------------|----------------------------------------------------------------------------------------|
| $q$ porte sur les contenus servis, projetés sur les bacs du catalogue | une étiquette se choisit, un contenu se constate                        | l'indice vaut 1,000 pour une diversité de contenu nulle, à coût nul                    |
| chaque rang est pondéré par $w_R$                                     | un lecteur consulte le premier élément bien plus souvent que le dernier | la norme se satisfait en enterant : 0,70 certifié, 0,36 exposé                         |
| le dénominateur $\log_2 k$ vient du catalogue déclaré                 | comparer deux plateformes exige la même unité                           | un fil fermé ne présente qu'une modalité, le dénominateur dé-génère et l'indice flatte |

**Remise d'attention.** Les résultats de cette note emploient  $w_R = 1/R$ , la remise du rang réciproque, usuelle en évaluation de classement. Le choix de  $w$  appartient au régulateur au même titre que le catalogue ; ce qui compte ici est qu'il soit *déclaré*, car c'est lui qui rend la norme non contournable par l'ordre.

**Grandeur de contrôle associée.** L'écart entre la valeur de (2) calculée sur la composition du fil ( $w_R$  constant) et sur sa distribution exposée ( $w_R = 1/R$ ) vaut zéro pour une plateforme qui ne relègue pas, et croît avec l'enterrement. C'est la seule grandeur de ce travail qui compare une mesure à *elle-même*, et donc la seule qui se seuille sans référence extérieure.

**Comment publier le chiffre.** Une entropie normalisée n'est pas une diversité : elle n'est pas linéaire en ce qu'on entend par « deux fois plus divers ». Sa conversion en **nombre effectif de points de vue**,  ${}^1D = k^{\text{IDE}}$ , l'est [Jost, 2006] : un plancher de 0,70 sur un catalogue de quatre vaut 2,6 points de vue effectifs, et les 0,44 réellement exposés par le fil enterrant en valent 1,9.

**Protocole.** L'unité est le contenu *servi*, non le contenu consulté : c'est la plateforme qui est auditée, pas le lecteur. L'indice se calcule par lecteur sur une fenêtre glissante, puis s'agrège ; la grandeur réglementaire est la *part de la population sous le seuil*, non la moyenne, car une moyenne satisfaisante peut masquer une minorité entièrement enfermée.

### 3 L'épreuve adverse

Une norme se juge à ce qu'elle contraint un adversaire rationnel à faire. Nous plaçons donc la plateforme dans le rôle qu'elle occupera : maximiser l'engagement *sous* la contrainte, et non s'y conformer de bonne foi.

**Méthode.** Le fil compte  $n$  positions à remplir depuis un catalogue de  $k$  points de vue, soit  $k^n$  fils possibles. Pour  $n = 8$  et  $k = 4$ , les 65 536 fils sont *tous énumérés* : l'optimum obtenu est exact, non le résultat d'une heuristique. Ce n'est pas un luxe. Il s'agit de résultats négatifs — des normes qui échouent — et un optimum manqué par un solveur produirait exactement l'apparence d'une norme qui tient.

#### 3.1 Une norme sur les étiquettes est saturable à coût nul

Si la plateforme contrôle l'étiquette indépendamment du contenu, l'entropie des étiquettes cesse de contraindre l'entropie des contenus. L'optimisation le confirme sans nuance : sous découplage complet, la plateforme obtient un indice de 1,000 — la note maximale — pour une diversité de contenu strictement nulle, sans céder un point d'engagement. Il n'est même pas nécessaire d'aller jusque-là : à mi-découplage, la contrainte n'a plus que 36 % de sa force.

La conséquence est directe : **la mesure doit porter sur les contenus servis**. Elle appelle un diagnostic complémentaire, l'*excès de signature* — l'écart entre deux indices calculés sur le même fil, rapporté à ce qu'un catalogue honnête afficherait au même indice — qui vaut zéro pour une plateforme honnête et croît avec le découplage.

#### 3.2 Le premier remplaçant prescrivait la polarisation

L'entropie quadratique de Rao [Rao, 1982] — la distance moyenne entre deux contenus tirés du fil, connue en recommandation sous le nom d'*intra-list distance* — semblait répondre à l'objection : elle voit les contenus, non les étiquettes. Son optimum sous contrainte d'engagement est pourtant **bimodal** : à diversité imposée, la façon la moins coûteuse de la fournir est de servir deux blocs extrêmes et de vider le centre. Une norme fondée sur elle prescrirait la polarisation qu'elle prétend

## Rang adverse et sévérité : ce qu'une norme aveugle laisse passer




FIGURE 1 – Diversité affichée contre diversité exposée sous plancher aveugle au rang; écart selon l'exigence du plancher; sévérité du biais de position retrouvée par effets fixes, et seuil d'exploration au-delà duquel elle cesse de l'être; coût d'un  $\eta$  posé au jugé.

mesurer. Ce défaut est connu de la littérature sur la diversification [Ohsaka and Togashi, 2023]; il est ici retrouvé comme conséquence directe de l'optimisation sous contrainte.

Le plancher retenu porte donc sur une *entropie*, calculée sur les contenus servis projetés sur les bacs du catalogue — mesure dont l'optimum sous contrainte est étalé et non bimodal.

### 3.3 Une norme aveugle au rang se contourne par l'enterrement

Les mesures ci-dessus portent sur la *composition* du fil. Reprises sur des fils *ordonnés*, les quatre mesures de diversité candidates se laissent toutes contourner de la même façon : servir les contenus divergents aux derniers rangs, où l'attention ne va plus.

| Mesure               | Coût                   | Affiché | Exposé       | Coût si conscient du rang |
|----------------------|------------------------|---------|--------------|---------------------------|
| Entropie de Rao      | 8,2 %                  | 0,750   | <b>0,355</b> | 18,9 %                    |
| Entropie de position | 10,7 %                 | 0,774   | <b>0,443</b> | 20,9 %                    |
| Gaussian ILD         | plancher inatteignable |         |              |                           |
| Proximité à la cible | 5,9 %                  | 0,750   | <b>0,628</b> | 10,6 %                    |

Le fil optimal a toujours la même forme : les contenus du point de vue préféré en tête, les divergents relégués. **Une plateforme certifiée à 0,70 n'expose que 0,36**. Un plancher conscient du rang ferme l'échappatoire et *double* le coût d'engagement : une norme qui ne coûterait pas davantage ne fermerait rien.

L'écart croît avec l'exigence — 0,262 à plancher 0,40, 0,395 à plancher 0,70 pour l'entropie de Rao : plus la norme aveugle demande de diversité, plus il devient rentable de l'enterrer.

## 4 Mesurer l'exposition

Tout ce qui précède suppose de savoir quelle attention va à quel rang. Le modèle usuel pose une probabilité d'examen décroissante avec le rang [Joachims et al., 2017],

$$e(R) = R^{-\eta}, \quad (3)$$

dont la sévérité  $\eta$  était, dans la première version de ce travail, *posée*. Elle s'estime.

### 4.1 Estimation par effets fixes de contenu

Sous (3), la probabilité de clic se factorise en  $P(\text{clic} \mid i, R) = g(i) R^{-\eta}$ , donc

$$\log \text{CTR}(i, R) = \log g(i) - \eta \log R. \quad (4)$$

La pertinence  $g(i)$  y est un effet fixe de contenu : on ne l'estime pas, on l'élimine par centrage intra-contenu. Ce qui subsiste est la seule variation qui identifie  $\eta$  — celle d'un *même contenu vu à des rangs différents*. C'est la forme la plus simple de la récolte d'interventions [Agarwal et al., 2019] : elle n'exige aucune expérience, seulement que la plateforme n'ait pas toujours classé les mêmes contenus aux mêmes places.

Sur données simulées, l'estimateur retrouve  $\eta$  de 0,4 à 1,6. À politique déterministe, il *refuse* de répondre plutôt que d'inventer un chiffre : aucun contenu ne change de rang, la sévérité n'est pas dans les données.

Poser  $\eta$  au lieu de l'estimer n'est pas anodin : sur un cas où le coût réel d'un filtre de diversité vaut 6,6 %, un  $\eta$  supposé de 0,5 le sous-estime de 59 % et un  $\eta$  supposé de 2,0 le surestime de 179 % — l'ordre de grandeur même du biais qu'on prétendait corriger.

### 4.2 Le contrôle qui doit précéder : l'échangeabilité

Le refus de répondre décrit ci-dessus attrape le cas visible — aucune variation de rang — et laisse passer le cas invisible : une variation *abondante et artificielle*. Il faut donc un contrôle qui ne compte pas la variation mais l'*informativité* de l'ordre.

Pour un fil de longueur  $L$  portant  $k$  clics, soit  $u_R = (R - 1/2)/L$  le rang normalisé. Sous l'hypothèse que les clics sont indifférents à la position à *fil donné*, les positions cliquées sont un tirage sans remise parmi les  $L$  positions, d'espérance et de variance connues exactement :

$$\mathbb{E}\left[\sum_{\text{clics}} u_R\right] = k \bar{u}, \quad \mathbb{V}\left[\sum_{\text{clics}} u_R\right] = \frac{k(L-k)}{L-1} \sigma_u^2. \quad (5)$$

Le conditionnement au fil rend le test immunisé au mélange des longueurs, à la qualité moyenne des contenus d'un fil et à l'appétit de clic de son lecteur. Un biais de position concentre les clics en haut : il rend l'écart réduit *négatif*, et le signe du rejet est donc lui-même une vérification.

Un test qui ne rejette rien ne dit rien tant qu'on ignore ce qu'il rejetterait. L'étalonnage se fait par simulation à structure de fils identique : sur celle de MIND, le test détecte  $\eta = 0,02$  à douze écarts-types, et la sévérité minimale détectable vaut  $\eta \approx 0,004$ .

## 5 Évaluer un réordonnement

Mesurer un fil est une chose ; estimer ce que coûterait un autre classement en est une autre. Les clics disponibles ont été produits par la politique de la plateforme, non par celle qu'on évalue.

**Le replay est faux, et d'un montant considérable.** Rejouer les clics enregistrés sur un fil réordonné se trompe de 201 % en médiane, jusqu'à 851 %, et le sens de l'erreur n'est pas garanti : sur soixante tirages à configuration identique, il surestime dans cinquante-six cas et sous-estime dans quatre. Un chiffre naïf n'est donc même pas une borne supérieure.

**La correction et son prix.** La pondération par l’inverse de la propension (*IPS*) est sans biais dès lors que la politique d’enregistrement est connue et donne une chance à toute action que la politique cible pourrait choisir. Son prix est la variance, d’où les variantes usuelles — auto-normalisation [Swaminathan and Joachims, 2015], plafonnement des poids — et le diagnostic qui doit accompagner tout chiffre : la **taille d’échantillon effective**, qui dit combien d’observations portent réellement l’estimation.

**Une confrontation à la vérité terrain.** L’Open Bandit Dataset [Saito et al., 2020] contient deux seaux servis en parallèle par deux politiques différentes, et publie les propensions vraies. On peut donc estimer la valeur de la politique uniforme *sur les seules données d’une autre politique*, puis la comparer à sa valeur mesurée là où elle a réellement servi.

| Estimateur                                    | Valeur   | Écart à la vérité |
|-----------------------------------------------|----------|-------------------|
| Vérité terrain (mesurée, 452 949 impressions) | 0,005124 | —                 |
| Naïf (taux de clic observé)                   | 0,006743 | +31,6 %           |
| IPS                                           | 0,005253 | + <b>2,5</b> %    |
| Auto-normalisé                                | 0,004768 | −7,0 %            |
| IPS plafonné à 10                             | 0,004473 | −12,7 %           |

La correction fonctionne. Le diagnostic interdit toutefois d’en tirer gloire : la taille d’échantillon effective vaut 1 513 pour 4 077 727 impressions, soit 0,04 %. L’estimation est sans biais et repose sur l’équivalent de mille cinq cents observations ; que l’écart tombe à 2,5 % tient autant à la chance qu’à la méthode. C’est le cas réel qui justifie la règle : publier la taille effective à côté du chiffre.

## 6 Trois journaux publics

Les instruments des §4 et §5 décident si un jeu de données permet la mesure. Appliqués à trois journaux publics, ils donnent trois réponses différentes.

### 6.1 MIND : un ordre qui n’en est pas un

Le jeu de référence de la recommandation d’actualité [Wu et al., 2020] présente une couverture de rang idéale : un contenu médian y apparaît à seize positions distinctes. Le test (5) n’y détecte pourtant rien —  $z = +0,12$  ( $p = 0,91$ ) sur 156 965 fils, répliqué à  $z = +0,28$  sur le second découpage — dans un jeu où il détecterait  $\eta = 0,02$  à douze écarts-types. L’ordre enregistré est indiscernable d’un mélange.

La courbe de taux de clic par position y décroît pourtant de 0,108 à 0,038 et s’ajuste à  $\hat{\eta} = 0,39$  : c’est un *artefact de composition*, les positions profondes n’existant que dans les fils longs, dont le taux de clic par contenu est mécaniquement plus faible. À longueur de fil fixée, la pente est nulle et change de signe d’une longueur à l’autre.

Enfin l’estimateur (4) accepte ce jeu, se déclare identifiable, et rend une sévérité qui est une fonction croissante d’un simple seuil de nuisance : −0,131 à cinq impressions, +0,053 à vingt, +0,255 à cent, toutes assorties d’une erreur type inférieure à 0,007. **Cinq chiffres confiants et incompatibles tirés du même jeu.**

Le mélange ne débiaise pas les clics : ceux-ci ont été produits sous l’ordre réel et en portent le biais en entier. Ce que le mélange retire est le *rang*, seul régresseur qui permettrait d’en tenir compte. Sur un journal simulé de sévérité vraie 1,00, l’estimation passe de 1,003 à −0,003 après mélange, à clics identiques ; l’évaluation d’un réordonnancement y devient vide par construction.




FIGURE 2 – Ce qu'un rang réellement servi fait à la courbe de taux de clic ; le test d'échangeabilité sur MIND et sur Baidu-ULTR ; l'effet de position mesuré sans modèle sur le seau aléatoire de l'Open Bandit Dataset ; l'estimateur contrefactuel jugé contre la valeur qu'il estime.

## 6.2 Baidu-ULTR : le contrôle positif

Sur une tranche de 524 164 documents servis en 64 200 sessions de recherche [Zou et al., 2022], le même test rejette à  $z = -205,7$  ( $p < 10^{-12}$ ) et du côté que la théorie prescrit. La sévérité y vaut  $\hat{\eta} = 1,10 \pm 0,09$  par effets fixes de document, contre 1,49 par ajustement agrégé — l'écart étant le confondant de qualité, la plateforme plaçant les meilleurs documents en tête. La couverture reste mince : 55 documents portent l'estimation, sur 444 709, parce qu'une même URL réapparaît rarement.

## 6.3 Open Bandit Dataset : la position mesurée sans modèle

Le seau aléatoire affecte les contenus aux positions au hasard : l'écart de taux de clic entre positions y est un effet *causal*, sans modèle d'examen à poser. Sur un bandeau de trois vignettes horizontales, il vaut  $\hat{\eta} = 0,037$  (campagne « all », 1,37 million d'impressions) à  $\hat{\eta} = 0,105$  (campagne « men »).

$\eta$  est donc une propriété de la surface, non une constante : un ordre de grandeur sépare une page de résultats verticale d'un bandeau de trois vignettes. Transporter la valeur de l'une à l'autre est exactement l'erreur dont §4 chiffre le coût.

## 6.4 Ce que ces trois journaux ne permettent pas

Aucun ne porte à la fois le *rang servi* et une *étiquette de point de vue interprétable*. MIND a les catégories éditoriales sans le rang ; Baidu-ULTR a le rang sans étiquette ; l'Open Bandit Dataset a le rang, la propension et trois attributs catégoriels, mais anonymisés — et une diversité

calculée sur des hachages ne dit rien, le catalogue de référence étant une déclaration politique.

L’indice de la §2 n’a donc jamais été mesuré sur un fil réel. Ce n’est pas une lacune de méthode : c’est une lacune de donnée.

## 7 Ce qu’il faut demander

L’article 40 du *Digital Services Act* [European Union, 2022], rendu opérationnel par le règlement délégué (UE) 2025/2050 [Commission européenne, 2025], ouvre aux chercheurs agréés un accès aux données des très grandes plateformes. Une demande n’y est recevable que si elle est *nécessaire et proportionnée*. « Donnez-nous vos journaux » ne l’est pas : cela réclame des données personnelles dont l’analyse n’a aucun besoin, et cela offre le motif de refus le plus facile — sécurité du service et secret des affaires.

Nous spécifions donc la demande sous forme de **quatre tableaux agrégés** :

1. **profils de fils** — pour chaque forme de fil servie (la liste des rangs qu’elle occupe) et chaque nombre de clics, le nombre de fils ;
2. **clics par rang** — pour chaque profil, chaque nombre de clics du fil et chaque rang, le nombre de clics ;
3. **cellules (contenu, rang)** — impressions et clics, et la propension de service si la plateforme la connaît ;
4. **exposition par (rang, point de vue)** — impressions et clics, sur le catalogue déclaré par le régulateur.

Aucune ligne ne désigne un lecteur : un fil n’y figure que par sa forme et par le nombre de clics reçus.

**Suffisance vérifiée, non affirmée.** Le test (5) se recalcule depuis les seuls tableaux 1 et 2 à  $3 \times 10^{-12}$  près sur MIND comme sur Baidu-ULTR ; la sévérité (4) se recalcule *exactement* depuis le tableau 3 ; les deux mesures de diversité depuis le tableau 4, qui suffit donc à constater l’enterrement — à composition identique, un fil conforme au plancher aveugle n’expose que 0,160 d’attention aux points de vue minoritaires, contre 0,375 en composition.

**Proportionnalité chiffrée.** Ce qui est demandé pèse 5 543 lignes pour les 524 164 documents servis de la tranche Baidu-ULTR (rapport 95) et 57 906 lignes pour les 5 843 444 contenus servis de MIND (rapport 101).

**Le seuil de confidentialité n’est pas neutre.** Supprimer les cellules de faible effectif protège les lecteurs et déplace les estimations : passer de 5 à 20 impressions par cellule fait passer la sévérité estimée de 1,10 à 1,40, soit +27 %, parce que les cellules rares sont celles des rangs profonds. Le seuil doit être fixé dans la demande et publié avec le résultat.

**Deux clés d’agrégation plus simples ont été écartées** parce qu’elles étaient fausses sans être visibles : indexer les fils par leur longueur plutôt que par leur profil de rangs — faux dès qu’une surface saute des rangs — et omettre le nombre de clics du fil, qui empêche d’écarter les fils entièrement cliqués et décale l’écart réduit de  $-205,7$  à  $-203,9$ . Les deux produisaient des chiffres du bon ordre de grandeur.

## 8 Un filtre qui optimise l’indice

Un algorithme de recommandation classique ordonne les contenus par pertinence estimée. Le filtre proposé ici ajoute un terme :

$$S(i, c) = \text{Pertinence}(i, c) + \mu \Delta H(i, c), \quad \mu \geq 0, \quad (6)$$






FIGURE 3 – Ce que la demande pèse face au journal ; l'écart entre mesure directe et mesure agrégée ; l'effet du seuil de confidentialité sur la sévérité estimée ; l'enterrement constaté sur le seul tableau d'exposition.

où  $\Delta H$  est la variation d'indice qu'apporterait le contenu  $i$  au fil  $c$ . À  $\mu = 0$ , le classement est *identique* à celui d'un filtre d'engagement : la transformation est un ajout paramétré, non une refonte. Le paramètre  $\mu$  suit un recuit — il monte lorsque l'indice passe sous le seuil, redescend une fois l'indice rétabli — de sorte que l'intervention soit intermittente.

**État.** Ce filtre est validé sur son propre modèle, avec une pertinence synthétique et quatre points de vue. Son coût réel en pertinence perçue n'est pas mesuré, et ne peut pas l'être sur données publiques en l'état (§6). Ce qui borne la discussion est le chiffre de la §3 : un plancher conscient du rang coûte 10,6 à 20,9 % d'engagement selon la mesure retenue, sur des fils de huit positions énumérés exhaustivement.

## 8.1 Ce qu'il vaut, comparé à des lignes de base

Un filtre ne se juge pas contre le classement par pertinence, dont il diffère par construction, mais contre ce qu'un praticien ferait sans théorie. Nous le comparons donc à quatre lignes de base — servir les points de vue à tour de rôle, la diversification *maximal marginal relevance* [Carbonell and Goldstein, 1998], un tirage de Boltzmann sur la pertinence, et le tirage au sort — et surtout à la **frontière exacte** du plan (diversité exposée, engagement), obtenue en énumérant les 151 200 arrangements ordonnés de six contenus tirés d'un vivier de dix.

Sur 150 viviers, à plancher fixé, le manque à gagner médian est le suivant.

| Méthode        | 0,50  | 0,60  | 0,70   | 0,80         | 0,90         |
|----------------|-------|-------|--------|--------------|--------------|
| Tour de rôle   | 0,0 % | 0,0 % | 0,0 %  | 3,8 %        | 4,8 %        |
| MMR            | 0,0 % | 0,0 % | 0,0 %  | <b>0,0 %</b> | <b>0,2 %</b> |
| Boltzmann      | 0,0 % | 0,0 % | 0,1 %  | 1,2 %        | 3,7 %        |
| Filtre (6)     | 0,0 % | 0,0 % | 0,0 %  | <b>0,0 %</b> | <b>1,0 %</b> |
| Tirage au sort | 9,3 % | 9,8 % | 11,0 % | 12,9 %       | 19,1 %       |

Le filtre se tient donc sur la frontière — ce qui n’était pas acquis, le tirage au sort atteignant les mêmes diversités en laissant un cinquième de l’engagement sur la table — mais **il n’y est pas seul**. Une heuristique publiée en 1998 y est aussi, et le devance en duel direct au plancher 0,80. Le filtre ne s’en détache qu’à l’exigence haute : au plancher 0,90, MMR ne trouve aucun réglage conforme dans 47 % des viviers, contre 12 % pour lui, parce qu’il optimise la grandeur contrainte là où MMR optimise un substitut qui sature.

**Le prix de la norme dépend du lecteur.** La comparaison ci-dessus tire la pertinence indépendamment du point de vue. En faisant varier cet *alignement*, le coût du plancher 0,90 passe de 3,8 % d’engagement — lecteur dont les intérêts traversent les points de vue — à 17,1 % — lecteur dont la préférence *est* un point de vue. La norme coûte donc le plus cher exactement là où elle sert le plus, ce qui prédit où portera l’objection. Cette dépendance réconcilie les chiffres de §3, où la pertinence était attachée au point de vue, avec ceux de ce paragraphe.

## Deuxième partie

# Le modèle d’arrière-plan

Ce qui précède se tient sans ce qui suit. L’indice, ses attaques, le test d’échangeabilité et les estimateurs contrefactuels ne dépendent d’aucune hypothèse sur la dynamique de l’opinion : ce sont des mesures sur des fils servis et des clics observés.

Cette partie expose le modèle d’où l’indice est *issu*. Elle a deux fonctions, et une seule est scientifique. La première est de rendre compte de la provenance : la grandeur retenue en §2 n’a pas été choisie au hasard parmi les mesures de diversité possibles, elle vient d’un formalisme qui décrit l’opinion comme un système à température. La seconde est de dire ce que ce formalisme vaut, mesure faite — et §15 conclut que l’analogie qui l’a suggéré ne survit à aucun de ses transferts.

Aucun résultat de la partie I ne repose sur cette partie-ci.

## 9 Formalisme entropique

### 9.1 Deux entropies, une même grandeur

L’entropie de von Neumann [von Neumann, 1932]

$$S(\rho) = -\text{Tr}(\rho \ln \rho) \quad (7)$$

est nulle pour un état pur. Son calcul passe par diagonalisation : les valeurs propres de  $\rho$  forment une distribution classique à laquelle on applique l’entropie de Shannon [Shannon, 1948]

$$H(X) = -\sum_i p_i \log_2 p_i. \quad (8)$$

C’est précisément ce qui autorise le pont entre les deux disciplines : l’entropie de von Neumann *est* l’entropie de Shannon du mélange révélé par la base propre.




FIGURE 4 – Consensus et susceptibilité en fonction de la température sociale (Monte-Carlo, réseau  $24 \times 24$ ). Le pic de susceptibilité localise la transition. Le décalage vers le haut par rapport à la valeur d’Onsager (10) est un effet de taille finie, non une erreur d’implémentation.

## 9.2 Une précision nécessaire

Il faut écarter d’emblée une formulation courante et fautive. L’évolution d’un système quantique *fermé* est unitaire, donc son entropie de von Neumann est constante. Ce qui croît sous l’effet de la décohérence est l’entropie du *sous-système réduit*, obtenue en traçant sur les degrés de liberté de l’environnement.

Il en découle une clarification — qui limite l’analogie plus qu’elle ne l’étend, voir §15 : une superposition cohérente est un état *pur*, d’entropie nulle. Ce n’est donc pas la multiplicité des possibilités qui produit du désordre, mais la perte de cohérence entre elles. Le pendant social est plus juste ainsi : une population où chacun garde plusieurs opinions ouvertes n’est pas désordonnée — le désordre naît du contact avec un environnement qui fixe les positions.

# 10 Dynamique thermodynamique

## 10.1 Modèle d’Ising et température sociale

Chaque individu porte une opinion binaire  $s_i \in \{-1, +1\}$  et la population suit la distribution de Gibbs-Boltzmann [Ising, 1925] :

$$P(\sigma) = \frac{1}{Z} \exp\left(\frac{J \sum_{\langle i,j \rangle} s_i s_j + H \sum_i s_i}{k_B T}\right), \quad (9)$$

où  $J$  mesure la force de conformisme local,  $T$  la *température sociale* (agitation, irrationalité, ouverture aux fluctuations) et  $H$  le champ médiatique externe.

L’intérêt du modèle ne réside pas dans l’analogie mais dans une propriété vérifiable : l’existence d’une température critique. En dimension deux, sa valeur exacte est connue [Onsager, 1944] :

$$\frac{T_c}{J} = \frac{2}{\ln(1 + \sqrt{2})} \approx 2,269. \quad (10)$$

C’est le seul point de ce travail où une prédiction théorique exacte, indépendante de nos hypothèses sociologiques, peut valider l’implémentation. La figure 4 la retrouve numériquement ; l’écart résiduel s’explique par les effets de taille finie sur un réseau de  $24 \times 24$ .




FIGURE 5 – À gauche, cycles d’hystérésis sous et au-dessus de  $T_c$  : dans le premier cas l’opinion reste aimantée alors que le champ est nul. À droite, décroissance de la mémoire avec la température sociale — fondement de la recommandation d’injection de bruit.

## 10.2 Énergie libre

Le système minimise son énergie libre de Helmholtz  $F = E - TS$ , où  $E$  représente la tension du désaccord et  $TS$  la force de dispersion. Quand  $N$  croît, l’entropie de configuration croît avec elle et le terme  $TS$  finit par dominer  $E$ .

## 10.3 Hystérésis sociale

C’est le résultat le plus directement actionnable. Sous  $T_c$ , couper le champ médiatique ( $H \rightarrow 0$ ) ne ramène pas l’aimantation à zéro : le terme d’interaction  $-J \sum s_i s_j$  prend le relais et le groupe maintient la croyance par cohésion interne.

Le cycle se lit en trois temps, qui sont ceux d’une crise médiatique : injection d’un champ massif, démenti officiel, puis nécessité d’un contre-champ  $-H$  dépassant le champ coercitif du groupe. La figure 5 montre que l’aire du cycle décroît avec la température sociale et s’annule au-dessus de  $T_c$ .

*Conséquence pratique* : le *debunking* passif ne fonctionne pas. Rétablir la neutralité informationnelle laisse la croyance en place ; seule une contre-information active, ou une hausse de la température sociale, la dissipe.

## 11 Effet de taille : temps de consensus

Le Voter Model [Clifford and Sudbury, 1973, Holley and Liggett, 1975] isole la contagion sociale pure, sans température : à chaque interaction un individu adopte l’opinion d’un voisin tiré au hasard. Il fournit des lois d’échelle exactes pour le temps de consensus, mesuré en balayages ( $N$  interactions élémentaires).

Les mesures (figure 6) donnent un exposant  $\approx 1$  en champ moyen et  $\approx 2$  sur un anneau. **Un réseau densément connecté converge donc plus vite qu’un voisinage géographique.**

Cette observation infirme un argument fréquent, selon lequel la structure « petit monde » des réseaux sociaux [Watts and Strogatz, 1998] empêcherait le consensus. La connectivité ne fragmente pas : elle accélère et amplifie, dans la direction que le champ lui donne. Les causes de la fragmentation sont le *biais directionnel* des micro-champs algorithmiques et l’*homophilie* qui compartimente le graphe [Pariser, 2011]. La conséquence pour la régulation est nette : le levier utile porte sur le champ, non sur le nombre de liens.




FIGURE 6 – À gauche, temps de consensus en fonction de la taille de la population, en échelle log-log, pour deux topologies. À droite, trajectoires de la fraction favorable au champ pour trois intensités de biais : c'est le biais, non la connectivité, qui décide de l'issue.

## 12 Paysage de l'opinion publique

### 12.1 L'équation et sa dérive

À l'échelle macroscopique, l'opinion collective  $x \in [-1, 1]$  obéit à une équation de Fokker-Planck [Risken, 1989] :

$$\frac{\partial P(x, t)}{\partial t} = -\frac{\partial}{\partial x} [A(x)P(x, t)] + \frac{\partial^2}{\partial x^2} [B(x)P(x, t)]. \quad (11)$$

Le potentiel quadratique  $V(x) = -\frac{J}{2}x^2 - Hx$ , qui vient naturellement à l'esprit, ne peut produire *aucune* transition de phase : l'exponentielle correspondante est convexe, donc maximale aux extrêmes à toute température. Le terme manquant est l'entropie de mélange, c'est-à-dire le nombre de configurations individuelles compatibles avec une opinion moyenne  $x$ . En l'ajoutant, on retrouve l'énergie libre de Helmholtz :

$$f(x) = \underbrace{-\frac{J}{2}x^2 - Hx}_E + T \underbrace{\left[ \frac{1+x}{2} \ln \frac{1+x}{2} + \frac{1-x}{2} \ln \frac{1-x}{2} \right]}_{-S}, \quad (12)$$

d'où la dérive

$$A(x) = -f'(x) = Jx + H - T \operatorname{artanh}(x). \quad (13)$$

Le rappel entropique  $-T \operatorname{artanh}(x)$  borne la dynamique dans  $(-1, 1)$  et fait apparaître une température critique de champ moyen  $T_c = J$ . La forme  $A(x) = Jx + H$  en est la linéarisation au voisinage de  $x = 0$ .

### 12.2 La diffusion et l'effet de $N$

Le terme de diffusion s'écrit

$$B(x) = \frac{k_B T (1 - x^2)}{N}, \quad (14)$$

le facteur  $(1 - x^2)$  éteignant le bruit à l'unanimité.

Le facteur  $1/N$  demande une lecture attentive, car il paraît contredire l'hypothèse de départ : plus la population est grande, *moins* sa variable macroscopique est bruitée. Il n'y a pas de contradiction, mais deux échelles distinctes. L'entropie de configuration totale est extensive et croît comme  $N$  ; les fluctuations de la moyenne  $x$  décroissent en  $1/N$ . La thèse défendable est donc :




FIGURE 7 – Paysage d’énergie libre (12), distributions stationnaires associées et scission temporelle d’une société initialement modérée. Le solveur est en volumes finis à flux nul aux bords : la masse de probabilité est conservée à  $10^{-15}$ , ce qui distingue un effondrement réel de la modération d’une fuite numérique.

Une grande population ne devient pas bruyante, elle devient *rigide*. Sa taille ne l’agite pas, elle la prive de plasticité stochastique — et c’est cette rigidité qui rend la polarisation irréversible, un système sans bruit ne pouvant plus quitter le puits de potentiel où il est tombé.

Cette reformulation est plus forte que l’hypothèse initiale : elle explique l’irréversibilité, ce que la métaphore de la « pompe à entropie » ne faisait pas.

### 12.3 Trois régimes

La distribution d’équilibre prend la forme de grandes déviations  $P_{\text{stat}}(x) \propto \exp(-Nf(x)/T)$ , où le facteur  $N$  rend la pénalité d’autant plus sévère que la population est grande. Trois régimes en découlent, obtenus en faisant varier deux paramètres (figure 7) : société fluide ( $T > T_c$ ), polarisée ( $T < T_c$ ,  $H = 0$ ) et manipulée ( $T < T_c$ ,  $H > 0$ ). Dans le dernier cas, le pic situé du côté du champ écrase l’autre : le « faux consensus » n’est pas une hypothèse ajoutée, c’est le puits incliné.

La densité de modérés décroît exponentiellement avec  $N$ . Dans une grande population sous  $T_c$ , la modération n’est pas minoritaire : elle est statistiquement inaccessible.

### 12.4 Franchissement de barrière

Le passage d’un bloc à l’autre sans traverser la modération relève du franchissement de barrière par activation thermique, de taux  $\propto e^{-\Delta V/k_B T}$  [Kramers, 1940], et non d’un effet tunnel — lequel n’a pas d’équivalent classique. La distinction n’est pas cosmétique : la loi de Kramers fournit une dépendance en température donc une prédiction testable.

## 13 Cinétique de résonance algorithmique

Une fausse information et un algorithme de recommandation forment une boucle de rétroaction positive analogue à l’effet Larsen. La visibilité  $V(t)$  obéit à

$$\ddot{V} + (\lambda - \gamma\alpha\sigma(V))\dot{V} + \omega_0^2 V = \xi(t), \quad (15)$$

où  $\lambda$  est l’amortissement naturel (l’oubli),  $\gamma$  le gain algorithmique,  $\alpha$  la charge émotionnelle du contenu, et  $\sigma(V) = 1/(1 + (V/V_{\text{sat}})^2)$  un facteur de saturation traduisant la finitude de l’attention disponible.

Le critère d’instabilité est

$$\boxed{\gamma\alpha > \lambda} \quad (16)$$




FIGURE 8 – À gauche, trois destins pour un même contenu : amorti, résonant borné, résonant non borné. À droite, amplitude du cycle limite en fonction du gain algorithmique ; le seuil mesuré coïncide avec  $\gamma^* = \lambda/\alpha$ .

Au-delà, l’amortissement effectif devient négatif : le système accumule l’énergie au lieu de la dissiper. La figure 8 vérifie que le seuil mesuré coïncide avec  $\gamma^* = \lambda/\alpha$ .

Sans saturation, la solution instable diverge comme  $e^{(\gamma\alpha-\lambda)t}$ , ce qui est exact mais inexploitable : une visibilité infinie n’existe pas et aucun seuil n’est calibrable sur un modèle divergent. Avec saturation, le système s’installe dans un cycle limite — une oscillation médiatique auto-entretenu d’amplitude finie, ce qui correspond au comportement observé d’une fausse information installée.

Un point mérite d’être souligné pour la régulation. À gain *uniforme*, un contenu plus émotionnel franchit le seuil qu’un contenu factuel ne franchit pas. Une plateforme n’a donc pas besoin de favoriser la désinformation pour l’amplifier sélectivement : le biais est mécanique. C’est ce qui rend la mesure de  $\gamma$  plus pertinente, et plus opposable, qu’un audit d’intentions éditoriales.

## 14 Calibration empirique du rapport d’amplification

Le critère (16) est resté longtemps une inégalité formelle : rien n’indiquait où se situent les systèmes réels. Nous l’estimons ici sur des séries d’attention publiques.

### 14.1 Identification

Pour un pic d’attention isolé, non oscillatoire, (15) se réduit à sa forme du premier ordre  $\dot{V} = \gamma\alpha\sigma(V)V - \lambda V$ , qui se sépare en deux régimes mesurables : pendant la *montée*, la saturation est inactive et  $V \propto e^{(\gamma\alpha-\lambda)t}$  ; pendant la *décroissance*, l’amplification est éteinte et  $V \propto e^{-\lambda t}$ . Deux régressions log-linéaires donnent donc

$$\lambda = r_{\text{down}}, \quad \gamma\alpha = r_{\text{up}} + r_{\text{down}}, \quad \frac{\gamma\alpha}{\lambda} = 1 + \frac{r_{\text{up}}}{r_{\text{down}}}. \quad (17)$$

### 14.2 Données

Les séries proviennent de l’API de consultations de Wikimedia, filtrées sur l’agent **user** pour exclure les robots, sur un corpus de 24 sujets *pré-enregistré* et réparti en deux registres émotionnels — accusation ou scandale d’une part, découverte non programmée d’autre part. Wikipédia étant dépourvue d’algorithme de recommandation, le  $\gamma$  ainsi estimé est un gain d’*écosystème* et non la fonction de classement d’une plateforme.

### 14.3 Résultats

Dix-neuf épisodes sont exploitables. Le rapport vaut entre 1,5 et 12, de médiane 2,5 à 4,2 selon l'estimateur (figure 9). Trois enseignements, dont deux négatifs.

**Le critère de signe est vide.** Le rapport dépasse 1 dans tous les épisodes et sous tous les estimateurs. Ce n'est pas une propriété de l'écosystème mais une *tautologie de la procédure* : un épisode observable a nécessairement connu une phase de croissance, donc  $r_{\text{up}} > 0$ . La recommandation « interdire les configurations où  $\gamma\alpha > \lambda$  » est par conséquent inapplicable, et doit être remplacée par un **plafond**  $\gamma\alpha/\lambda \leq \rho_{\text{max}}$ . Cette erreur n'était pas détectable par relecture : seule la tentative de mesure l'a révélée.

**La valeur dépend de la méthode.** Avec des fenêtres délimitées par le retour au niveau de fond, leur durée varie de 6 à 46 jours ; l'attention décroissant plus lentement qu'une exponentielle, un ajustement sur une fenêtre longue produit un  $\lambda$  plus faible. La corrélation de rang atteint  $-0,94$ . Un second estimateur, à horizon fixe, rend  $\lambda$  comparable entre épisodes ; la médiane varie néanmoins d'un facteur 1,7 selon l'estimateur retenu, ce qui interdit d'adosser un seuil réglementaire à une valeur unique.

**Le mécanisme de la charge émotionnelle n'est pas étayé.** Aucun écart détectable entre les deux registres ( $p \geq 0,13$ ), et l'estimation ponctuelle va dans le sens contraire à la prédiction. Les effectifs sont faibles et le biais de sélection décrit ci-dessous écarte les cas les plus chargés ; il serait donc excessif d'y voir une réfutation — mais le mécanisme ne peut pas être présenté comme soutenu par les données.

**La méthode est aveugle aux régimes installés.** Onze sujets sur vingt-quatre ne livrent aucun épisode exploitable, et ce sont les cas archétypaux : QAnon, désinformation sanitaire, hésitation vaccinale. Leur attention ne forme pas un pic mais un *palier durable*, que le niveau de fond glissant absorbe — la détection par proéminence ne les voit pas. La procédure sélectionne donc contre le phénomène même que la théorie décrit, ce qui constitue la limite la plus lourde de cette calibration.

## 15 L'analogie de départ, et son verdict

Ce travail est parti d'une analogie : plus un système quantique est grand, plus vite il décohère ; plus une population est grande, plus l'accord y est difficile. Elle a produit des quantités mesurables — un indice de diversité, un seuil d'amplification, une température critique — et c'est son mérite. Ses affirmations propres ont été vérifiées une à une, et aucune n'a tenu.






FIGURE 9 – Un épisode d’attention et ses deux régimes exponentiels ; la distribution du rapport par registre émotionnel ; la sensibilité de la médiane au choix d’estimateur ; et l’artefact de fenêtre qui a imposé l’estimateur à horizon fixe.

| Ce que l’analogie affirmait                       | Verdict                                                                                                                                                                                                                                                                                   |
|---------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Plus le système est grand, plus il se désor-donne | <b>faux, et à l’envers</b> : le terme de diffusion re-tenu, $B(x) = k_B T(1 - x^2)/N$ , rend la variable macroscopique <i>plus</i> déterministe à grand $N$ . Deux objets étaient confondus — l’entropie de configuration, extensive, et le bruit de la va-riable macroscopique, en $1/N$ |
| La décohérence augmente l’entropie                | <b>faux</b> : l’évolution d’un système fermé est uni-taire. C’est l’entropie du sous-système <i>réduit</i> qui croît                                                                                                                                                                      |
| $\tau_D \propto \tau_R/N$                         | loi d’échelle <b>heuristique</b> , non le résultat de Zurek, qui fait intervenir la séparation spatiale et la longueur d’onde thermique                                                                                                                                                   |
| « Effet tunnel social »                           | <b>métaphore</b> : l’analogue correct est le fran-chissement de barrière par activation [Kramers, 1940], qui est classique                                                                                                                                                                |
| $1/k^N$ mesure l’improbabilité du consensus       | décrit un <b>état initial</b> tiré au hasard, non une dynamique                                                                                                                                                                                                                           |

S’y ajoute une erreur de raisonnement qui n’est pas physique : le récit d’origine attribuait la fragmentation à la connectivité des réseaux « petit monde » [Watts and Strogatz, 1998]. En champ moyen, le Voter Model converge en  $O(N)$  : la connectivité *accélère* le consensus. La fragmentation

vient du biais  $H_i$  et de l'homophilie, non de la topologie seule.

Ce qui subsiste — paysage d'énergie libre, transition de phase, hystérésis, franchissement de barrière — relève de la mécanique statistique classique, dans la lignée d'Ising et de la sociophysique [Galam, 2004, Castellano et al., 2009]. Rien de spécifiquement quantique n'a survécu au passage.

L'analogie a donc fonctionné comme **échafaudage** : elle a suggéré des quantités mesurables qui lui survivent. C'est un rôle réel, et il ne se confond pas avec la vérité. Il serait malhonnête de la qualifier de « féconde donc juste » : elle a suggéré des mesures, et aucune de ses affirmations n'a résisté à la vérification. L'indice a d'ailleurs été renommé en conséquence — il s'appelait *Index de Dissipation Entropique*, d'après la décohérence, et s'appelle désormais *Indice de Diversité Exposée*, d'après ce qu'il mesure.

## Troisième partie

# Réserves

## 16 Limites

Ces limites sont énoncées ici plutôt que laissées aux relecteurs.

### 16.1 Sur l'indice et la norme

**La forme retenue n'a jamais été mesurée sur un fil réel.** Elle est définie (2), son coût est chiffré par énumération exhaustive, et c'est tout. La lacune est de *donnée*, non de méthode (§6), et §7 dit ce qu'il faudrait pour la combler.

**Le niveau du plancher n'est pas déductible de la mesure.** Ce travail établit la forme de la norme et son prix, pas sa valeur. Fixer 0,60 plutôt que 0,40 est une décision politique qu'aucun calcul présenté ici ne tranche.

**La discrétisation en points de vue est un choix politique.** Qui définit les modalités définit l'indice. La mesure par divergence à un catalogue déclaré rend ce choix explicite au lieu de l'enfourir ; elle ne le supprime pas.

**L'indice reste manipulable au-delà de ce qu'une mesure automatique détecte.** Les attaques de §3 sont fermées, mais une plateforme peut encore servir des contenus formellement divergents et substantiellement vides — de la diversité de bac sans diversité d'argument. Toute métrique imposée devient une cible.

**Un plancher est une contrainte sur ce que les citoyens voient.** C'est défendable, mais c'est une intervention sur le débat public, et la présenter comme une simple mesure technique serait malhonnête. La mesure sur des fils individuels soulève en outre une question de vie privée à laquelle §7 ne répond qu'en partie, par l'agrégation.

### 16.2 Sur les mesures d'exposition

**La forme  $e(R) = R^{-\eta}$  est posée.** Seule sa sévérité est estimée. Un modèle d'examen à cascade, ou dépendant du contenu, produirait une autre dépendance au rang — que le test (5) détecterait tout aussi bien, puisqu'il ne teste que l'indépendance, mais que la sévérité minimale détectable ne résumerait plus.

**L'énumération exhaustive borne la taille des fils.** Huit positions sur quatre points de vue. Rien n'assure que l'enterrement se comporte ainsi sur un fil de cinquante items, et l'affirmer demanderait une optimisation approchée dont il faudrait établir qu'elle n'invente pas le résultat.

**Les jeux mesurés sont des tranches.** Une tranche de Baidu-ULTR n'est pas Baidu-ULTR ; l'Open Bandit Dataset mesure une recommandation de mode sur trois vignettes horizontales, et le transport de ses chiffres vers un fil d'actualité est précisément l'opération que §6 déconseille.

**La confrontation à la vérité terrain porte sur une politique cible uniforme** , la seule dont ce jeu contienne un seau. Rien n'assure que la pondération d'importance se comporte aussi bien pour une cible plus éloignée de la politique d'enregistrement — au contraire, la taille d'échantillon effective y serait plus faible encore.

### 16.3 Les deux hypothèses les plus profondes, éprouvées

Deux hypothèses traversent toute cette note sans avoir été mises à l'épreuve : que l'examen suit une loi de puissance, et que la pertinence est connue. Aucune ne l'est.

**Le test d'échangeabilité survit à un changement de modèle de clic.** Sous un modèle à *cascade* [Craswell et al., 2008] — le lecteur descend le fil, s'arrête dès qu'il a trouvé, et poursuit sinon avec une probabilité  $\gamma$  — le test (5) rejette entre  $z = -208$  et  $z = -241$  selon  $\gamma$ , soit *plus fortement* que sur Baidu-ULTR. C'est le résultat qu'il fallait obtenir : le test ne suppose rien de la forme de l'attention, il ne teste que l'indépendance, et son verdict négatif sur MIND garde donc son sens sous n'importe quel modèle.

**La loi de puissance, elle, ne survit pas.** Sous cascade, la décroissance de l'examen est *géométrique* et non polynomiale. La simulation rend ici la vérité terrain que les données réelles ne donnent jamais — les positions effectivement examinées — et la comparaison est sans appel : au douzième rang, la loi  $R^{-\hat{\eta}}$  ajustée surestime l'exposition réelle d'un facteur 40 à  $\gamma = 0,95$ , 129 à  $\gamma = 0,85$  et 4110 à  $\gamma = 0,60$ . L'ajustement paraît pourtant excellent, avec une erreur type de 0,04.

La conséquence porte directement sur §6 : la sévérité  $\hat{\eta} = 1,10 \pm 0,09$  mesurée sur Baidu-ULTR n'a de sens *que si* l'examen y suit une loi de puissance — et Baidu-ULTR est une page de résultats de recherche, terrain d'élection du modèle à cascade. La sévérité doit donc être publiée **avec la forme supposée**, et cette forme reste à tester. Le test d'échangeabilité dit si l'ordre porte de l'information ; il ne dit pas sous quelle forme.

**Et une pertinence estimée efface l'avantage des méthodes réglées.** La comparaison de §8.1 suppose la pertinence connue. En faisant classer les méthodes sur une pertinence *perçue* et en les jugeant sur la vraie, leur ordre ne change pas — le filtre et MMR restent devant — mais leur avantage sur le tirage au sort passe de 16,4 points à bruit nul à 5,8 points pour une corrélation de rang de 0,50, et *s'inverse* en deçà de 0,36. La raison est mécanique : le tirage au sort est le seul réordonnateur qui n'utilise pas la pertinence, donc le seul dont le manque à gagner soit invariant au bruit.

À pertinence réaliste, l'écart entre réordonnateurs compte donc bien moins que la qualité du moteur de pertinence sous-jacent — ce qui renforce, par une troisième voie, la conclusion que la contribution de ce travail n'est pas son algorithme.

### 16.4 Un troisième contrôle : la forme de l'examen

Le test d'échangeabilité dit si l'ordre d'un journal porte de l'information ; il ne dit pas sous quelle forme, et §16.3 a montré que la forme décide de tout. Un troisième contrôle s'impose donc, et il repose sur une *indépendance conditionnelle* plutôt que sur une allure : sous un modèle de

position, l'examen du rang  $R$  ne dépend que de  $R$ , donc le clic  $y$  est indépendant de ce qui s'est passé au-dessus ; sous cascade, un clic au-dessus supprime l'examen en dessous.

Pour chaque cellule  $s = (\text{contenu}, \text{rang})$ , les  $n_s$  impressions se répartissent en  $n_{1s}$  précédées d'un clic et  $n_{0s}$  qui ne le sont pas, pour  $k_s$  clics au total. Sous l'hypothèse d'indépendance, ces clics se répartissent comme un tirage sans remise :

$$\mathbb{E}[a_s] = \frac{k_s n_{1s}}{n_s}, \quad \mathbb{V}[a_s] = \frac{k_s(n_s - k_s) n_{1s} n_{0s}}{n_s^2(n_s - 1)}. \quad (18)$$

C'est la statistique de Mantel-Haenszel, stratifiée par cellule ; le conditionnement élimine la qualité du contenu.

**Le contrôle fonctionne.** Il ne rejette jamais sous modèle de position ( $|z| < 1$  pour  $\eta \in \{0; 0,5; 1; 2\}$ ) et rejette massivement sous cascade ( $z = -97$  à  $-307$ ).

**Mais il ne tranche pas ce qu'il devait trancher.** Un lecteur qui cesse de cliquer une fois servi — tout en continuant de parcourir le fil — produit la même signature :  $z = -144$  sous modèle de position *pur* avec un budget de un clic, contre  $-179$  sous cascade. Rien dans les clics ne les distingue, et c'est attendu : dans les deux cas le journal montre qu'après un clic il n'y a plus rien. La différence est pourtant décisive, puisque sous budget le contenu placé sous un clic est examiné, et sous cascade il ne l'est pas.

**Sur Baidu-ULTR, aucune signature de cascade.** L'écart réduit  $y$  est *positif* —  $+5,6$  au seuil le plus permissif,  $+0,5$  à  $+0,6$  aux plus stricts — alors qu'une cascade le rendrait négatif. Le signe est celui du confondant d'hétérogénéité, que le test annonçait comme sa limite. Trois lectures restent ouvertes : l'examen  $y$  est proche d'un modèle de position ; une cascade existe mais le confondant la masque ; ou la couverture est trop mince, 108 cellules au seuil le plus strict.

**Une erreur de protocole, rattrapée.** Restreindre le journal aux sessions à plusieurs clics — où un budget de un est exclu par construction — semblait la façon évidente de séparer les deux modèles, et donne sur Baidu-ULTR  $z = -8,2$  ( $p = 2 \times 10^{-16}$ ). Le nombre de clics d'un fil est pourtant un *collider* de ses clics individuels : conditionner dessus induit entre eux une dépendance négative, et fabrique donc la signature recherchée. Sur un journal simulé sous modèle de position pur, la même restriction fait passer  $z$  de  $+0,74$  à  $-45,7$ . Ce qui était mesuré n'était pas une propriété du journal mais la sélection opérée.

**Ce qui trancherait.** Une mesure de l'*examen* plutôt que du clic — temps d'affichage, profondeur de défilement, contenu sorti de l'écran. Baidu-ULTR publie ces colonnes ; ce travail ne les a pas lues.

## 16.5 L'exposition mesurée plutôt qu'estimée

Baidu-ULTR publie une colonne `displayed_time` — le temps d'affichage de chaque document — que ce travail n'avait pas lue. Elle mesure directement ce qui a été *montré*, là où tout ce qui précède n'observait que ce qui avait été *cliqué*.

**Elle lève l'ambiguïté de §16.4.** Sur les clics, cascade et budget sont confondus ; sur l'examen, la séparation est totale :  $z = -158$  à  $-412$  sous cascade contre  $z = -1,03$  sous budget, quel que soit le budget. Appliquée à Baidu-ULTR, la mesure **réfute la cascade** : l'examen sous un clic  $y$  est *plus* fréquent, pas moins —  $0,221$  contre  $0,136$  au neuvième rang,  $z = +8,4$  à  $+10,9$  selon le seuil. C'est le confondant d'hétérogénéité, mesuré directement.

**Elle révisé le chiffre publié.** La sévérité de l'exposition, mesurée par effets fixes de document sur l'affichage, vaut  $0,882 \pm 0,046$  sur **143** documents, contre  $1,085 \pm 0,093$  sur 55 pour l'estimation par les clics. L'estimation **surestime la décroissance de 23 %**, et l'écart n'est pas une imprécision mais un confondant identifié : un clic est le produit de l'examen et de l'attrait, et l'attrait décroît lui aussi avec le rang.

**Elle met en cause la forme employée partout.** Ajustées sur la courbe *mesurée*, les trois formes candidates donnent  $R^2 = 0,72$  pour la loi de puissance — avec 42 % d'écart maximal —, 0,96 pour une décroissance géométrique et 0,99 pour un modèle à *pli d'écran*. La loi en  $R^{-\eta}$  est la pire des trois, et elle se trompe surtout là où la norme se joue : au deuxième rang, elle prédit 0,47 quand la mesure donne 0,88.

**Conséquence sur §7.** Les quatre tableaux demandés portent sur les clics. Une colonne de plus — le nombre d'impressions effectivement *affichées* par cellule — retirerait d'un coup le besoin d'estimer  $\eta$ , l'hypothèse de forme qui l'accompagne, et le confondant d'attrait. Elle est en outre moins sensible que les clics : savoir qu'un contenu a été affiché en dit moins sur un lecteur que savoir qu'il l'a choisi.

**Réserve.** Un temps d'affichage positif atteste que le document a été montré, non qu'il ait été regardé. La mesure surestime donc l'exposition, dans une proportion que ce travail ne peut pas chiffrer.

## 16.6 Le format, le retour, et une explication retirée

Deux colonnes de Baidu-ULTR restaient inexploitées : `slipoff_count_after_click`, qui compte les documents sortis de l'écran après un clic, et `media_type`, qui distingue les formats d'affichage.

**La cascade réfutée une seconde fois.** La première colonne est non nulle pour 43,7 % des lignes cliquées et 0,5 % des autres : après un clic, le journal enregistre explicitement que des documents ont défilé, donc que le lecteur est revenu. Sous cascade stricte, elle serait toujours nulle. La part croît d'ailleurs avec la profondeur du clic — 0,37 au premier rang, 0,59 au sixième. La réfutation de §16.5, obtenue par un test statistique, est ainsi confirmée par un fait consigné, ce qui est une voie indépendante.

**Le format modifie l'exposition, et pas par la géométrie.** Un format enrichi — encadré de réponse, image, tableau — est plus haut : 273 pixels en médiane contre 192. On attendrait donc un effet de repoussement. À rang *et* à hauteur cumulée comparables, un format enrichi au-dessus retire pourtant 8,4 points d'examen à ce qui suit, médiane sur 21 strates toutes de même signe. L'effet ne passe donc pas par la place occupée, et l'explication qui reste est celle de la *satisfaction* : un encadré répond à la question, et le lecteur cesse de descendre.

La conséquence porte sur toute mesure fondée sur le rang seul, y compris la nôtre : l'exposition au rang  $R$  dépend du **format de ce qui est au-dessus**, et aucune loi  $e(R)$  ne peut la représenter puisqu'elle ne prend pas la page en argument. La remise d'attention  $w_R$  de (1) n'est donc pas une propriété de la surface mais de la **page servie** : deux fils de composition identique, servis avec des formats différents, n'exposent pas la même chose.

**Et une explication de cette note est retirée.** §16.5 attribuait la forme en deux temps de la courbe mesurée à un *pli d'écran*, et invoquait la colonne `serp_height`. Cette colonne permet de tester l'hypothèse, et elle la réfute : le rang explique mieux l'examen ( $R^2$  de McFadden 0,082) que la hauteur cumulée au-dessus (0,057), et les pixels n'ajoutent que 0,0007 une fois le rang connu. Le constat — la courbe n'est pas une loi de puissance — tient ; l'explication mécanique tombe.

**Conséquence sur §7.** Le tableau des cellules réclame déjà une colonne d’affichagees ; il en faut une de plus, le **format** du contenu servi. Sans elle, deux fils de composition identique peuvent exposer des diversités différentes sans que rien ne le signale. C’est en outre la moins sensible des colonnes demandées : le format d’un contenu ne dit rien de son lecteur.

## 16.7 Ce que la contre-expertise a retiré ou restreint

Les instruments de mesure ont été confrontés à la littérature du domaine et à quatre contre-épreuves. Trois résultats de cette note en sortent modifiés.

**Une conclusion retirée.** La comparaison des quatre mesures de diversité (§3) était menée *au même plancher nominal*. Les mesures ne vivant pas sur la même échelle, cette comparaison n’a pas de sens : à diversité réellement exposée égale, les deux mesures retenues coûtent la même chose, à moins de 0,6 % de la borne exacte. L’affirmation selon laquelle la proximité à une cible « résisterait mieux » à l’enterrement est un artefact d’échelle. Ce qui fait la norme est le **niveau** exigé et la **conscience du rang**, non le choix de la mesure.

**Une conclusion restreinte.** Le chiffre « certifiée à 0,70, elle expose 0,36 » suppose une remise d’attention en  $1/R$ , c’est-à-dire  $\eta = 1$ . Recalculé avec la sévérité *mesurée* d’un bandeau de trois vignettes ( $\eta \approx 0,1$ ), le même fil expose 0,747 : l’enterrement disparaît. À  $\eta = 2$  il n’expose que 0,157, et l’échappatoire ne coûte plus que 2,7 % au lieu de 20,8 %. La remise d’attention doit donc être **mesurée sur la surface**, et le prix stable est celui de la norme consciente du rang — 20,8 à 24,1 % selon la surface.

**Une incertitude élargie.** L’estimateur de §4 suppose un modèle de clic multiplicatif. La littérature en documente un *affine*, où le lecteur clique par confiance sur des contenus non pertinents en tête de fil [Vardasbi et al., 2020], et démontre que la pondération par l’inverse de la propension ne peut pas le corriger. Sous ce modèle, la sévérité estimée dérive de +12,8 % sans que l’erreur type ne le signale. C’est bien moins grave que de poser  $\eta$  au jugé, mais l’intervalle publié est trop étroit.

**Une recommandation confirmée.** L’estimateur doublement robuste fait *moins bien* que la pondération simple sur l’Open Bandit Dataset (−4,9 % contre +2,5 %), et la taille d’échantillon effective ne bouge pas : elle ne dépend que des poids d’importance. Aucun estimateur ne remplace l’exploration.

**Et une mise en garde de la littérature.** Sur Baidu-ULTR — le jeu même où cette note mesure  $\hat{\eta} = 1,10$  — Hager et al. [2024] constatent que les corrections de biais de position améliorent la prédiction des clics *sans* améliorer la qualité du classement jugée par des annotateurs experts. La présence du biais est confirmée par quatre méthodes concordantes, ce qui corrobore notre chiffre ; l’étape suivante, elle, ne suit pas mécaniquement.

## 16.8 Sur le modèle

**Calibration à peine entamée.** Un seul paramètre composite est estimé (§14) ;  $J$ ,  $T$ ,  $\gamma$  et  $\alpha$  pris séparément n’ont aucune procédure d’estimation. La voie la plus prometteuse serait l’inférence des coefficients de Kramers-Moyal sur des séries d’opinion longues, qui permettrait de *tester* la dérive plutôt que de l’ajuster.

**La seule prédiction propre du modèle n’est pas vérifiée.** Le mécanisme de la charge émotionnelle  $\alpha$  prédit une différence entre registres — amplification, persistance, taux de basculement. Quatre mesures indépendantes, dont une réplication sur 440 sujets et une annotation en aveugle à double codage, n’en retrouvent aucune trace. L’écart apparent du corpus pilote était un artefact de sélection.

**Une analogie n’est pas une explication.** Rien ici ne démontre que les opinions *obéissent* à une mécanique statistique ; le travail établit qu’un formalisme emprunté à la physique en *reproduit* des comportements. Sur l’analogie de départ elle-même, le verdict est plus net encore (§15).

**Les individus ne sont pas des spins.** L’intentionnalité, l’ironie et l’anticonformisme stratégique n’ont pas d’équivalent dans un modèle de spins ; les opinions sont multidimensionnelles [Deffuant et al., 2000]. Surtout, l’environnement n’est pas passif : un algorithme optimise une fonction de coût, ce qui en fait un acteur stratégique plutôt qu’un bain thermique. C’est le point le plus fragile de l’analogie — et c’est aussi ce qui rend concevable le filtre de §8 : une fonction de coût peut être changée.

**Portée des simulations.** Les régimes explorés ont été choisis pour leur lisibilité. Aucune étude systématique de sensibilité n’a été menée, les tailles de systèmes sont modestes, et les conclusions de la partie II sont qualitatives : elles portent sur l’existence de régimes et le sens des dépendances, jamais sur des valeurs numériques transposables.

## 16.9 Sur l’annotation

**Les codeurs ne sont pas indépendants.** Le double codage en aveugle du corpus donne un  $\kappa$  de Fleiss de 0,921, mais les trois codeurs sont des instances du même modèle de langue : leur accord surestime nécessairement ce que produiraient des juges humains indépendants. C’est la dernière réserve de méthode qui ne se lève pas par le calcul.

## 17 Reproductibilité

L’intégralité du travail est disponible en accès libre et exécutable en conteneur, avec 556 tests automatisés. Les vérifications structurantes portent sur la température critique d’Onsager (10), la conservation exacte de la masse de probabilité, les exposants des lois d’échelle du temps de consensus, la positivité de l’aire du cycle d’hystérésis sous  $T_c$ , l’équivalence du filtre (6) avec un filtre d’engagement à  $\mu = 0$ , le signe du rejet du test d’échangeabilité sur un journal réellement ordonné, et l’exactitude des mesures recalculées depuis les tableaux agrégés de §7.

Les journaux d’impressions employés ne sont pas redistribués — ils pèsent de 135 Mo à 2,2 Go et portent chacun sa licence — mais le dépôt en conserve des condensés vérifiés, qui rendent à l’identique tous les chiffres publiés ici. Chaque figure est régénérée par un notebook.

<https://github.com/s-geffroy/Indice-Diversite-Exposee>  
<https://s-geffroy.github.io/Indice-Diversite-Exposee/>

Ce travail est ouvert à la relecture critique. Les retours les plus utiles porteraient sur la forme retenue de l’indice et sur le niveau d’un éventuel plancher, ou sur les instruments de mesure des §4 et §5, où une erreur méthodologique serait la plus coûteuse.

## Références

Aman Agarwal, Ivan Zaitsev, Xuanhui Wang, Cheng Li, Marc Najork, and Thorsten Joachims. Estimating position bias without intrusive interventions. In *Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining*, pages 474–482, 2019.

- Jaime Carbonell and Jade Goldstein. The use of MMR, diversity-based reranking for reordering documents and producing summaries. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 335–336, 1998.
- Claudio Castellano, Santo Fortunato, and Vittorio Loreto. Statistical physics of social dynamics. *Reviews of Modern Physics*, 81(2) :591–646, 2009.
- Peter Clifford and Aidan Sudbury. A model for spatial conflict. *Biometrika*, 60(3) :581–588, 1973.
- Commission européenne. Règlement délégué (ue) 2025/2050 du 1<sup>er</sup> juillet 2025 complétant le règlement (ue) 2022/2065 en ce qui concerne l’accès aux données des chercheurs agréés. Journal officiel de l’Union européenne, 2025. entré en vigueur le 29 octobre 2025.
- Nick Craswell, Onno Zoeter, Michael Taylor, and Bill Ramsey. An experimental comparison of click position-bias models. In *Proceedings of the 2008 International Conference on Web Search and Data Mining*, pages 87–94, 2008.
- Guillaume Deffuant, David Neau, Frederic Amblard, and Gérard Weisbuch. Mixing beliefs among interacting agents. *Advances in Complex Systems*, 3(01n04) :87–98, 2000.
- European Union. Regulation (eu) 2022/2065 on a single market for digital services (digital services act). Official Journal of the European Union, 2022.
- Serge Galam. Sociophysics : a personal testimony. *Physica A*, 336(1-2) :49–55, 2004.
- Philipp Hager, Romain Deffayet, Jean-Michel Renders, Onno Zoeter, and Maarten de Rijke. Unbiased learning to rank meets reality : Lessons from baidu’s large-scale search dataset. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2024.
- Richard A. Holley and Thomas M. Liggett. Ergodic theorems for weakly interacting infinite systems and the voter model. *The Annals of Probability*, 3(4) :643–663, 1975.
- Ernst Ising. Beitrag zur theorie des ferromagnetismus. *Zeitschrift für Physik*, 31(1) :253–258, 1925.
- Thorsten Joachims, Adith Swaminathan, and Tobias Schnabel. Unbiased learning-to-rank with biased feedback. In *Proceedings of the Tenth ACM International Conference on Web Search and Data Mining*, pages 781–789, 2017.
- Lou Jost. Entropy and diversity. *Oikos*, 113(2) :363–375, 2006.
- Hendrik A. Kramers. Brownian motion in a field of force and the diffusion model of chemical reactions. *Physica*, 7(4) :284–304, 1940.
- Naoto Ohsaka and Riku Togashi. A critical reexamination of intra-list distance and dispersion. In *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 1619–1628, 2023.
- Lars Onsager. Crystal statistics. i. a two-dimensional model with an order-disorder transition. *Physical Review*, 65(3-4) :117–149, 1944.
- Eli Pariser. *The Filter Bubble : What the Internet Is Hiding from You*. Penguin Press, 2011.
- C. Radhakrishna Rao. Diversity and dissimilarity coefficients : A unified approach. *Theoretical Population Biology*, 21(1) :24–43, 1982.
- Hannes Risken. *The Fokker-Planck Equation : Methods of Solution and Applications*. Springer, 2 edition, 1989.



- Yuta Saito, Shunsuke Aihara, Megumi Matsutani, and Yusuke Narita. Open bandit dataset and pipeline : Towards realistic and reproducible off-policy evaluation. *arXiv preprint arXiv :2008.07146*, 2020.
- Claude E. Shannon. A mathematical theory of communication. *Bell System Technical Journal*, 27 (3) :379–423, 1948.
- Adith Swaminathan and Thorsten Joachims. The self-normalized estimator for counterfactual learning. In *Advances in Neural Information Processing Systems 28*, pages 3231–3239, 2015.
- Ali Vardasbi, Harrie Oosterhuis, and Maarten de Rijke. When inverse propensity scoring does not work : Affine corrections for unbiased learning to rank. In *Proceedings of the 29th ACM International Conference on Information and Knowledge Management*, pages 1475–1484, 2020.
- John von Neumann. *Mathematische Grundlagen der Quantenmechanik*. Springer, 1932.
- Duncan J. Watts and Steven H. Strogatz. Collective dynamics of ‘small-world’ networks. *Nature*, 393(6684) :440–442, 1998.
- Fangzhao Wu, Ying Qiao, Jiun-Hung Chen, Chuhan Wu, Tao Qi, Jianxun Lian, Danyang Liu, Xing Xie, Jianfeng Gao, Winnie Wu, and Ming Zhou. MIND : A large-scale dataset for news recommendation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 3597–3606, 2020.
- Lixin Zou, Haitao Mao, Xiaokai Chu, Jiliang Tang, Wenwen Ye, Shuaiqiang Wang, and Dawei Yin. A large scale search dataset for unbiased learning to rank. *arXiv preprint arXiv :2207.03051*, 2022.